

דוח פרויקט למידת מכונה: חיזוי דירוגי סרטים

מגישה: נטע אור שאול

בפרויקט זה נדרשנו לבנות מודל ללמידת מכונה שמטרתו לחזות את הדירוג הממוצע של סרטים (averageRating), עוד לפני יציאתם לאקרנים. הדגש המרכזי במשימה הוא לבצע חיזוי על סמך מידע שזמין מראש בלבד, מבלי להשתמש במאפיינים שנאספים לאחר יציאת הסרט.

הדאטה עליו עבדתי מבוסס על סט הנתונים שקיבלנו שבנינו בחלק הראשון של המטלה. על מנת לבנות וללמד את המודלים שיהיה כמה שיותר מדויקים החלטתי לסנן את הסרטים כך שהדאטה תכלול רק סרטים שיש להם דירוג.

לאחר סינון הנתונים החסרים של משתנה המטרה ולפני כל עבודה נוספת על הדאטה חילקתי את הדאטה ל- Train (80%) ו- Test (20%) על מנת למנוע זליגת מידע כך שהדאטה מחולק כמצורף :

```
Split completed with Leakage Protection:  
- Training set features shape: (92448, 7)  
- Testing set features shape: (23112, 7)
```

רק לאחר חלוקת הדאטה התחלתי לעבוד על הפיצ'רים כמתואר בטבלה הבאה:

פיצ'ר	סוג	תיאור
runtimeMinutes	בסיסי	משך הסרט בדקות (כחלק מטבלת הנתונים הקיימת)
decade	נגזר מ- startYear	קיבוץ של שנים לפי עשורים, לדוגמה 1970-1979
genre_exmpale	קטגורי	ייצוג של כל ז'אנר (One-Hot Encoding) לדוגמה - genre_Drama
hist_genre_rating	מורכב (היסטורי)	דירוג ממוצע היסטורי עד השנה של השנה של הסרט לא כולל, לדוגמה סרט בשנת 1980 יקבל את הממוצע של הסרטים לפי הז'אנר הספציפי עד שנת 1979 וזאת על מנת למנוע זליגת נתונים. במקרים בהם לסרט יש יותר מז'אנר אחד הציון שיתקבל הוא ממוצע בין הז'אנרים של הסרט. חושב גם ממוצע היסטורי גלובלי הכולל את הממוצע של כל הז'אנרים וזאת על מנת לענות על מקרים בהם או הסרט בשנה מוקדמת ואין עליו עוד מידע או במקרים בהם יש ז'אנרים נדירים שלא מוכרים עוד.
hist_genre_runtime	מורכב (היסטורי)	אורך ממוצע של סרטים בז'אנר, גם כאן מחושב על סמך נתוני עבר וזאת על מנת למנוע זליגת נתונים. גם בפיצ'ר זה קיים ממוצע גלובלי עבור מקרים נדירים/חוסר.
runtime_deviation	מורכב	ההפרש בין אורך הסרט בפועל לבין האורך הממוצע ההיסטורי של הז'אנר שלו, משקף עד כמה הסרט חורג מהאורך של הסרטים בז'אנר שלו.

מאפשר ללמוד על סרטים "חריגים" יותר.		
דומה לפיצ'ר <code>hist_genre_rating</code>, עבור הפיצ'ר הנוכחי חושב דירוג ממוצע היסטורי של הבמאי על סמך סרטים קודמים בלבד, כך שכל סרט מקבל את ממוצע הדירוגים של הבמאי עד השנה שלפני יציאתו. במקרים בהם מדובר בבמאי ללא היסטוריה קודמת, נעשה שימוש בממוצע הגלובלי. גם כאן במקרים שיש יותר מבמאי אחד יחושב הממוצע ביניהם.	מורכב (היסטורי)	<code>director_hist</code>
פיצ'ר בינארי המציין אם לסרט יש יותר מבמאי אחד.	בינארי	<code>has_multiple_directors</code>
פיצ'ר המודד את השונות (סטיית תקן) של הדירוגים של סרטים קודמים של הבמאי וככה אפשר ללמוד על עקביות ויציבות הבמאי.	מורכב	<code>director_std_global</code>
פיצ'ר בינארי שמציין אם קיימת היסטוריה לבמאי בדאטה.	בינארי	<code>director_known</code>

- סט הפיצ'רים שנבנה כולל שילוב של פיצ'רים בסיסיים ופיצ'רים מורכבים, המבוססים על מידע היסטורי ואינטראקציות בין משתנים. פיצ'רים אלו מאפשרים למודל ללכוד דפוסים עמוקים יותר וגם לזהות חריגות מהנורמה. במהלך בניית הפיצ'רים ההיסטוריים הייתה מחשבה עמוקה על מניעת זליגת נתונים ומילוי ערכים חסרים שעלולים להיות בפיצ'רים האלו.

prepare_data - תיעוד השלבים

פונקציית `prepare_data` אחראית על עיבוד הנתונים הגולמיים והפיכתם לסט פיצ'רים המתאים למודל. לצורך יצירת הפיצ'רים ההיסטוריים, חושבו מראש סטטיסטיקות על סט האימון בלבד, ונשמרו במילונים לצורך גישה מהירה. לאחר מכן, נשמר מידע זה גם בקובץ חיצוני PKL, כך שניתן לטעון אותו בעת הצורך ולהשתמש בו ללא חישוב מחדש. במהלך הריצה, הפונקציה משתמשת במילונים הקיימים בזיכרון, או טוענת אותם מהקובץ במידה ואינם זמינים.

הפונקציה תוכננה כך שתזהה אם הדאטה שהתקבלה היא הדאטה הספציפית של ה `train` או כל דאטה אחרת המתקבלת כ- `test`. עבור כל קלט הפונקציה עובדת באופן זהה, ואינה מחשבת את הסטטיסטיקות מחדש. מנגנון הזהוי של הדאטה משמש לצורך בקרה בלבד ולא משפיע על העיבוד. דרך עבודה זו מבטיחה הפרדה בין שלבי האימון והבדיקה ומונעת זליגת נתונים.

תיעוד השלבים:

- ניקוי נתונים והכנה בסיסית- המרה של עמודות לנומריות כמו `startYear`, `runtimeMinutes` וטיפול בערכים חסרים בעמודת הז'אנרים והמרתם לערך "Unknown".
- טיפול בערכים חסרים - כאשר חסר ערך ל-`runtimeMinutes`, הוא מוחלף בחציון של הערכים בסט האימון, על מנת לשמור על יציבות ולהימנע מהשפעה של ערכים חריגים.
- יצירת פיצ'ר עשורים - חישוב פיצ'ר `decade` מתוך שנת היציאה של הסרט.

- ייצוג ז'אנרים - המרת רשימת הז'אנרים לכל סרט ויצירת One-Hot Encoding עבור כל ז'אנר על בסיס הערכים שנצפו ב־train.
 - פיצ'רים היסטוריים- שימוש במילונים שחושבו מראש לצורך שליפת נתונים היסטוריים:
 - דירוג ממוצע היסטורי לפי ז'אנר (hist_genre_rating)
 - אורך ממוצע היסטורי (hist_genre_runtime)
 - פיצ'ר מורכב- חישוב runtime_deviation כהפרש בין אורך הסרט בפועל לבין האורך הממוצע בז'אנר.
 - שילוב נתוני במאים - חיבור נתוני הבמאים לכל סרט וחישוב ממוצעי עבר (director_hist) על בסיס מידע היסטורי.
 - יצירת פיצ'ר has_multiple_directors
 - הוספת director_known_idirector_std_global מתוך mapping
 - ניקוי סופי - הסרת עמודות שאינן רלוונטיות למודל, והחזרת סט פיצ'רים נקי ומוכן לאימון.
- בסיום הרצת הפונקציה מתקבל סט פיצ'רים אחיד ומוכן למודלים.

השוואת מודלים

בוצעה השוואה בין שני מודלים Elastic Net ו-Random Forest, תוך שימוש ב-Cross Validation עם 10-fold CV כמבוקש בדרישות הפרויקט. לכל מודל חושבו שלושה מדדי ביצוע R^2 , MAE, RMSE ובנוסף חושבה סטיית התקן שלהם לצורך הערכת יציבות, תוצאות המודלים כמצורף:

--- Random Forest Evaluation ---				--- ElasticNet Evaluation ---			
	Metric	Mean	Std		Metric	Mean	Std
0	RMSE	1.0702	0.0123	0	RMSE	1.1154	0.0121
1	MAE	0.8120	0.0070	1	MAE	0.8541	0.0079
2	R^2	0.3161	0.0085	2	R^2	0.2572	0.0084

ניתן לראות כי מודל Random Forest מציג תוצאות טובות יותר בכל המדדים, RMSE ו-MAE נמוכים יותר - מעידים על שגיאה קטנה יותר בתחזיות. וערך R^2 גבוה יותר המעיד על יכולת הסברה טובה יותר של השונות בנתונים.

סטיות התקן של שני המודלים נמוכות מאוד, דבר המעיד על יציבות כללית בין ה-Fold. עם זאת, אין יתרון מובהק לאחד המודלים מבחינת יציבות, Random Forest מציג ביצועים טובים יותר למרות הבדל קטן בסטיית התקן.

לאחר צפייה בתוצאות נעדיף את מודל Random Forest אשר המדדים שלו טובים יותר.

ניתוח חשיבות פיצ'רים

לצורך הבנת חשיבות ותרומת הפיצ'רים השונים, בוצע ניתוח חשיבות פיצ'רים באמצעות שני המודלים.

כמצורף לפי סדר חשיבות הפיצ'רים לכל מודל:

	feature	coefficient	abs_coef
9	genre_Documentary	0.327686	0.327686
29	hist_genre_rating	0.218891	0.218891
16	genre_Horror	-0.216519	0.216519
32	director_hist	0.183677	0.183677
31	runtime_deviation	0.179082	0.179082

	feature	importance
29	hist_genre_rating	0.316253
31	runtime_deviation	0.129587
32	director_hist	0.125138
9	genre_Documentary	0.124210
34	director_std_global	0.104850

ניתן לראות שלשני המודלים יש חפיפה של 3 פיצ'רים הכי חשובים משותפים:

- hist_genre_rating
- director_hist
- runtime_deviation

החפיפה של הפיצ'רים בשני המודלים מחזקת החשיבות שלהם ומראה על כך שהם מהווים גורמים מרכזים בניבוי הדירוג.

ניתוח חשיבות הפיצ'רים מראה כי מידע היסטורי מהווה מרכיב מרכזי בניבוי איכות הסרטים. פיצ'רים כמו ביצועי ז'אנר ובמאים לאורך זמן משפיעים משמעותית על התחזית, יותר מאשר מאפיינים בסיסיים.

Analysis Error - ניתוח שגיאות

לצורך ניתוח שגיאות, נבחנו התחזיות שהתקבלו במסגרת Cross Validation עבור המודל הנבחר Random Forest. נבחרו 10 הסרטים עם ה-overprediction הגבוה ביותר כלומר המודל חזה דירוג גבוה מהמציאות, ו-10 סרטים עם ה-underprediction הגבוה ביותר המודל חזה דירוג נמוך מהמציאות. מקרים אלו מייצגים את השגיאות הקיצוניות ביותר של המודל, ומהווים בסיס לניתוח מעמיק של מגבלותיו.

דוגמאות לסרטים-

-Overprediction

- **Tribalism Is Killing Us** – המודל חזה דירוג גבוה 8.003 ובפועל הסרט קיבל דירוג נמוך מאוד של 1.3, פער זה מראה שהמודל מתקשה לזהות סרטים באיכות נמוכה במיוחד, כיוון שהוא למד בעיקר מאפיינים כלליים. בנוסף, המודל אינו כולל מידע על ביקורות או תגובות קהל אשר עשויים להסביר דירוגים נמוכים במיוחד, ולכן אינו מצליח להבחין בין סרטים מוצלחים לבין כאלו שקיבלו תגובות שליליות.
- **Play in the Gray** – המודל חזה דירוג של 7.2 ובפועל הסרט קיבל 1.3, כנראה שהמאפיינים של הסרט דומים לסרטי איכותיים יותר בדאטה ולכן המודל חזה בצורה שגויה. המקרה הזה מדגים לנו שהמודל מתקשה לזהות חריגים שלילים ונוטה להתקרב יותר לערכים הקרובים לממוצע.
- **Justin Bieber: Never Say Never** – המודל חזה 7.4 ובפועל הסרט קיבל 1.7 יכול להיות מצב שבו הסרט מכון לקהל יעד מסוים, יכול להיות שהפער נוצר מכך שהמודל לא לוקח בחשבון קהל יעד או פופולריות בפועל, לדוגמה מספר מצביעים ולכן יכול להיות שיש מצב שהמודל מתקשה להעריך סרטים מסוג זה.

-Underprediction

- **Il nostro paradiso** - המודל חזה 4.8 ובפועל הסרט קיבל דירוג גבוה מאוד של 9.5 המקרה הזה מדגיש את החולשה של המודל בזיהוי סרטים איכותיים במיוחד שאינם עוקבים אחרי הדפוסים הנפוצים. מדגיש שוב את הנטייה של המודל לחזור לערכי הממוצע.
- **Urban Savages** - המודל חזה 4.1 ובפועל הדירוג שהסרט קיבל הוא 8.6 מקרה זה מציג לנו מצב שבו הסרט מהווה חריגה חיובית ביחס לדפוסים הנפוצים בדאטה, כנראה שהפער נוצר מכך שהסרט איכותי ביחס לסרטים מהז'אנר שלו. המקרה מדגיש שוב את מגבלת המודל ביחס לערכים חריגים.

בנוסף לניתוח הסרטים הספציפיים, ביצעתי בחינה של כלל ה-outliers על מנת לזהות דפוסים כלליים בהתנהגות המודל. לצורך בחינה זה השווה התפלגות הדירוגים של הסרטים ב-outliers להתפלגות של כלל הדאטה, וכן הבחנה בין השגיאות מסוג Overprediction ו-Underprediction. כמצורף:

```
Full dataset:

... count      92448.000000
   mean         6.069898
   std          1.294308
   min          1.000000
   25%          5.300000
   50%          6.200000
   75%          7.000000
   max          9.900000
   Name: averageRating, dtype: float64
```

```
... === Outliers vs Full Data ===
Outliers:

... count      20.000000
   mean         5.190000
   std          3.805384
   min          1.000000
   25%          1.500000
   50%          5.250000
   75%          8.800000
   max          9.500000
   Name: actual, dtype: float64
```

```
... === Over vs Under ===

...
count mean std min 25% 50% 75% max
type
over  10.0  1.50 0.352767 1.0 1.300 1.5 1.60 2.3
under 10.0  8.88 0.434102 8.2 8.525 8.9 9.25 9.5

...

=== Mean Comparison ===
Dataset mean: 6.07
Outliers predictions mean: 5.82
```

מהבדיקה למדנו שהסרטים שנבחרו כ-outliers מאופיינים בערכים קיצוניים ביחד להתפלגות הדאטה הכללית. אפשר לראות שרוב הסרטים בדאטה נמצאים סביב הממוצע, והסרטים ב-outliers נמצאים בקצוות ההתפלגות, סביב דירוגים נמוכים או גבוהים יותר.

בנוסף נמצא כי ממוצע התחזיות עבור ה-outliers קרוב לממוצע הכללי, דבר המצביע על כך שהמודל נוטה לחזות ערכים קרובים לממוצע גם כאשר הערכים האמיתיים קיצוניים.

המודל מבוסס במידה רבה על פיצ'רים היסטוריים וממוצעים, ולכן לומד דפוסים כלליים ומתקשה לזהות סרטים חריגים. בנוסף המודל אינו כולל פיצ'רים המתייחסים לאיכות הסרט בפועל או הפופולאריות שלו ולכן מתקשה להבחין בסרטים במקרים האלה. כתוצאה מבחירת הפיצ'רים האלו המודל נוטה להתכנס יותר למרכז, לממוצע.

השוואה בין מודלים

לצורך השוואה בין המודלים נבחרו 20 סרטים עם השגיאות הגדולות ביותר עבור כל מודל, ונבדקה החפיפה ביניהם.

מהבדיקה הזאת נמצא שיש 11 סרטים חופפים ב-outliers בשני המודלים. כלומר שני המודלים נכשלו בחיזוי שלהם בצורה דומה.

דבר זה מצביע על כך שישנם סרטים שקשה לחזות אותם באופן כללי ללא תלות במודל. לכן אפשר ללמוד מזה שהשגיאות נגרמות כתוצאה ממגבלות של הדאטה ולא רק ממגבלות של מודל מסוים.

הצעות לשיפור

על בסיס ניתוח השגיאות ניתן לראות שהמגבלות העיקריות של המודל מופיעות בעיקר במקרים חריגים, או במקרים בהם חסר מידע על קהל יעד או לפופולאריות. בהתאם לכך, ניתן להציע מספר פיצ'רים ושיפורים שעשויים לשפר את תוצאות המודל:

- שיפור טיפול ב-outliers – ניתן לנסות לשפר את המודל עבור הערכים החריגים בכך שבזמן תהליך האימון ניתן משקלים שונים לערכים שקרובים/רחוקים יותר מהממוצע.
- מדד חריגות של ז'אנר- פיצ'ר שיבטא עד כמה הז'אנר נפוץ או נדיר בדאטה. יכול לעזור במקרים של סרטים נדירים שהמודל מתקשה לחזות.
- פיצ'ר קהל יעד- ניתן להוסיף פיצ'ר המבחין בין קהל יעד של ילדים/מבוגרים בדרך פשוטה דרך עמודה isAdult הקיימת בטבלאות של IMDB. פיצ'ר זה יכול לעזור למודל להבחין בקהל יעד של הסרט.
- פיצ'רים היסטוריים מורחבים המתייחסים לפופולאריות – אפשר להרחיב את הייצוג של הפיצ'רים ההיסטוריים ולחשב גם מדד המתייחס לכמות המצביעים באופן היסטורי עבור הז'אנרים או הבמאים ובכך להתייחס גם לפופולאריות של הז'אנר או הבמאי.

השיפורים המוצעים מתמקדים בהתמודדות טובה יותר של המודל עם מקרים חריגים, וגם בהשלמת חוסר מידע בנוגע למאפיינים כמו קהל יעד או פופולריות. שיפורים אלו יכולים לעזור למודל להבין טוב יותר מקרים שאינם מייצגים את הממוצע, וככה לשפר את דיוק התחזיות ולהפחית את השגיאות.

Analysis Fairness - ניתוח הוגנות

לצורך בדיקת הוגנות המודל נבחנו שני חתכים מרכזיים לבחינה: ז'אנרים ועשורים.

בחירה זו מאפשרת לבדוק האם המודל מתפקד באופן אחיד בין סוגים שונים של סרטים, או שיש קבוצות מסוימות בהן רמת הדיוק שונה.

לצורך בדיקת הוגנות לפי ז'אנר, נבחנו ביצועי המודל (MAE ו-RMSE) עבור כל אחד מהז'אנרים.

מהניתוח עולה כי קיימים הבדלים בביצועי המודל בין ז'אנרים שונים. ניתן לראות כי עבור ז'אנרים מסוימים, כגון Western ו-Film-Noir, מקבלים שגיאה נמוכה יחסית, המעידה על ביצועים טובים יותר של המודל. לעומתם, ז'אנרים אחרים כגון Horror ו-Sci-Fi, Animation מצגיגים ערכי שגיאה גבוהים יותר, מה שמעיד על קושי של המודל לחזות סרטים מסוג זה. ז'אנרים נפוצים יותר, כמו Comedy ו-Drama, מצגיגים רמת שגיאה בינונית, דבר המעיד על ביצועים יציבים יחסית של המודל, אך לא על דיוק גבוה במיוחד. מעניין לראות כי לעיתים ז'אנרים קטנים יותר מבחינת כמות הנתונים מצגיגים שגיאה נמוכה יותר. אבל צריך לשים לב להתייחס לתוצאה הזאת בזהירות, כיוון שמדדים המבוססים על מספר קטן של דוגמאות אינם בהכרח יציבים ואינם בהכרח מייצגים את ביצועי המודל בפועל.

בנוסף, ייתכן כי ז'אנרים קטנים הם גם דומים יותר, דבר שמקל על המודל ללמוד דפוסים. לעומת זאת, ז'אנרים גדולים ונפוצים יותר, כמו Comedy ו-Drama, כוללים מגוון רחב של סרטים, דבר המקשה על המודל ללמוד דפוסים אחידים ועלול להוביל לירידה מסוימת בדיוק החיזוי.

כמו כן, ז'אנרים מסוימים, כגון Horror ו-Sci-Fi, עשויים לכלול יותר מקרים חריגים או התנהגות פחות יציבה של דירוגים, ולכן קשים יותר לחיזוי עבור מודל המבוסס על ממוצעים.



לצורך בדיקת הוגנות לפי עשורים, נבחנו ביצועי המודל (MAE ו-RMSE) עבור כל עשור. מהניתוח עולה כי קיימים הבדלים מסוימים בביצועי המודל בין תקופות שונות. ניתן לראות כי עבור עשורים מוקדמים יותר (כגון 1930–1950) מתקבלים ערכי שגיאה נמוכים יחסית, בעוד שבעשורים מאוחרים יותר (כגון 2000–2020) ערכי השגיאה גבוהים יותר. פערים אלו עשויים להגרם כתוצאה מכך שבעשורים המאוחרים קיימת כמות גדולה ומגוונת יותר של סרטים, דבר המקשה על המודל ללמוד דפוסים אחידים. בנוסף, סרטים חדשים יותר עשויים להיות מגוונים יותר באופיים ולכלול יותר מקרים חריגים, דבר שמוביל לשגיאות גבוהות יותר. יחד עם זאת, צריך לשים לב כי עבור חלק מהעשורים המוקדמים מספר הסרטים קטן יחסית, ולכן המדדים עבורם פחות יציבים ואינם בהכרח מייצגים את ביצועי המודל באופן מלא.

ממצאים אלו מצביעים על כך שהמודל אינו מתפקד באופן אחיד בין כל הקבוצות, וקיימים חתכים בהם רמת הדיוק נמוכה יותר.

עם זאת, את הפערים שנמצאו אפשר להסביר במידה רבה על ידי מאפייני הדאטה, כמו כמות נתונים שונה בין הקבוצות ורמת גיוון גבוהה יותר בז'אנרים ובעשורים מסוימים.

לכן, לא ניתן לקבוע באופן חד משמעי כי קיימת הטיה שיטתית של המודל כלפי קבוצה מסוימת, אלא מדובר בקושי הנובע בעיקר ממאפייני הבעיה והנתונים עצמם.

הגרפים המצורפים מציגים את ביצועי המודל לפי ז'אנר ועשור, ומציגים באופן חזותי את הפערים ברמת הדיוק בין קבוצות שונות.



מניעת leakage data

במהלך העבודה הושקעה מחשבה רבה כדי למנוע מצב של זליגת מידע, גם בשלב בניית הפיצ'רים וגם בשלב האימון וההערכה.

הדאטה חולק לסט אימון וסט בדיקה לאחר סינון של ערכים חסרים של עמודות ציון ממוצע, וזאת כדי לוודא שמידע מסט הבדיקה אינו משפיע על חישוב הפיצ'רים או על תהליך האימון. בחישוב הפיצ'רים ההיסטוריים הוקפד כי לא יתבצע שימוש במידע מאותו פרק זמן אלא רק מנתוני עבר. כלומר, ממוצע של סרטים בשנה מסוימת אינו כולל את הסרט הנבחן עצמו, וכן לא נעשה שימוש בנתונים מסט הבדיקה לצורך חישובים אלו.

בנוסף, תהליך ההערכה התבסס על Cross Validation, כך שכל תחזית חושבה ללא שימוש במידע על אותה דוגמה עצמה, מה שמבטיח הערכה הוגנת וללא זליגת מידע.

מסקנות, מגבלות והצעות להמשך

בעבודה זו נבנה מודל לחיזוי דירוגי סרטים על בסיס מאפיינים שונים. המודל הצליח לזהות מגמות כלליות בדאטה, אבל נראה כי המודל מתקשה בעיקר במקרים חריגים ובדירוגים קיצוניים. מהניתוח ניתן לראות כי המודל נוטה לחזות ערכים קרובים לממוצע, ולכן השגיאות הגדולות יותר מופיעות כאשר הסרטים רחוקים מההתנהגות הממוצעת.

אחת המגבלות בעבודה נובעת ממבנה הדאטה, כאשר חלק מהעמודות המשמעותיות כמו תקציב, מדינה ושפה כללו כמות גדולה של ערכים חסרים. במקרה זה, במקום לבצע השלמות שעלולות להכניס רעש או הטיות, החלטתי להתמקד בפיצ'רים היסטוריים ומאפיינים כלליים, המאפשרים למודל ללמוד מגמות בצורה עקבית יותר.

עם זאת, העבודה מדגישה את החשיבות של בניית פיצ'רים מתאימים ואת ההשפעה שלהם על איכות המודל. להמשך, ניתן לשפר את המודל באמצעות שילוב מידע עשיר יותר, שימוש בשיטות מתקדמות יותר לטיפול בערכים חריגים, והוספת נתונים שיכולים לשקף טוב יותר את איכות הסרט וקהל היעד שלו.

-AI usage log

במהלך העבודה נעשה שימוש בכלי AI לצורך הבהרות והכוונות במספר שלבים, כמו ניסוחי קוד, הבנת שיטות עבודה עם מודלים, הבנה מעמיקה יותר של תוצאות המודלים ושיפור חלקי ניסוח.

כל שימוש ב-AI לווה בבדיקה עצמאית ומעמיקה של התוצאות כך שהשימוש ב-AI הוא כעזר בלבד. תהליך העבודה עצמו כלל חשיבה והבנה עצמאית, וה-AI לא שימש כתחליף לכך אלא כתמיכה בתהליך.